

SCRIPT-5.R

Tory Ferrer

2025-09-25

```
# LUIS MIGUEL TORIBIO FERRER
# 25/09/2025
# SEMANA 8

***Regresión lineal simple (sigue un patrón lineal entre sus variables)**

# Regresión -----

# X: variable independiente/explicativa/endógena
# Y: variable dependiente/respuesta/endógena
# El objetivo es tener estimaciones de Y para distintos valores de X a partir
# de n pares de valores

# Causalidad -----

# Hay una relación en X y Y pero tambien puede haber otra causa de esos resultados.
***Es saber si esa variable si afecta a la otra.**
# "No todo lo que tiene correlación tiene causalidad"

# Tipos de relación -----

# No determinista: Conociendo X, el valor de Y no queda perfectamente establecido.
#  $Y=f(x)+u$ 

# Lineal: cuando la función  $F(x)$  es lineal
#  $f(x)=B0+B1x$ 
***B0 es cuando la X vale 0 (intercepto) y B1 es la (pendiente)** (Pendiente/B1=
**Si aumento X, cuánto se aumenta en Y?)
# Si  $B0 < 0$  es lineal positiva.
# Si  $B0 > 0$  es lineal negativa.

# No lineal: cuando  $f(x)$  no es lineal
# Es una función logarítmica

# Ausencia de relación:  $f(x)=0$  =no hay correlación

# Mientras más llega a 1, es más correlación, 0 es que no hay relación.

# Modelo de regresión lineal simple -----
```

```

# (y prima)  $Y_i = B_0 + B_1 x_i + E_i$ 
# Error=residuo  $e_i = Y_i - Y_i(\text{prima})$ 

# Supuestos -----

# 1: Linealidad: relación entre x y y lineal.
# 2: Homogeneidad: valor promedio del error = 0.
# 3: Homocedasticidad: la varianza de los errores es constante.
# 4: Independencia: observaciones independientes.
# 5: Normalidad: errores siguen una distribución lineal.

# Estimadores de mínimos cuadrados -----

***Gauss 1809**
# B0 y B1
# Minimizar la suma de los residuos al cuadrado = residuales al cuadrado y su
# sumatoria.

# Ejercicio 1 -----

datos <- data.frame(
  trigo = c(30, 28, 32, 25, 25, 25, 22, 24, 35, 40),
  harina = c(25, 30, 27, 40, 42, 40, 50, 45, 30, 25)
)
datos

```

```

##      trigo harina
## 1      30      25
## 2      28      30
## 3      32      27
## 4      25      40
## 5      25      42
## 6      25      40
## 7      22      50
## 8      24      45
## 9      35      30
## 10     40      25

```

```

sumxi_yi <- sum(datos$trigo*datos$harina)
sumxi_yi # =9734

```

```
## [1] 9734
```

```

nxy <- length(datos$trigo)*mean(datos$trigo)*mean(datos$harina)
nxy

```

```
## [1] 10124.4
```

```
sumxi_yi-nxy # ==-390.4
```

```
## [1] -390.4
```

```
xi2 <- sum(datos$trigo^2)
```

```
xi2 # ==8468
```

```
## [1] 8468
```

```
nx2 <- length(datos$trigo)*mean(datos$trigo)^2
```

```
nx2 # ==81796
```

```
## [1] 8179.6
```

```
b1 <- (sumxi_yi - nxy)/(xi2-nx2)
```

```
b1 # ==-1.353675
```

```
## [1] -1.353675
```

```
b0 <- mean(datos$harina) - b1*mean(datos$trigo)
```

```
b0 # ==74.11512
```

```
## [1] 74.11512
```

```
fit.lm <- lm(datos$harina ~ datos$trigo)
```

```
fit.lm
```

```
##
```

```
## Call:
```

```
## lm(formula = datos$harina ~ datos$trigo)
```

```
##
```

```
## Coefficients:
```

```
## (Intercept)  datos$trigo
```

```
##      74.115      -1.354
```

```
summary(fit.lm)
```

```
##
```

```
## Call:
```

```
## lm(formula = datos$harina ~ datos$trigo)
```

```
##
```

```
## Residuals:
```

```
##      Min       1Q   Median       3Q      Max
```

```
## -8.5049 -2.9164  0.7268  3.3457  5.6657
```

```
##
```

```
## Coefficients:
```

```
##              Estimate Std. Error t value Pr(>|t|)
```

```
## (Intercept)  74.1151     8.7358   8.484 2.85e-05 ***
```

```
## datos$trigo  -1.3537     0.3002  -4.509 0.00198 **
```

```
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 5.098 on 8 degrees of freedom
## Multiple R-squared:  0.7176, Adjusted R-squared:  0.6824
## F-statistic: 20.33 on 1 and 8 DF,  p-value: 0.001978

# Coefficients: (Intercept) B0 = intercepto 74.1151 =2.85e-05 *** muy significativo
#      datos$trigo -1.3537 B1 = pendiente -1.3537 =0.00198 ** muy significativo

anova(fit.lm)
```

```
## Analysis of Variance Table
##
## Response: datos$harina
##              Df Sum Sq Mean Sq F value    Pr(>F)
## datos$trigo   1 528.47   528.47   20.333 0.001978 **
## Residuals     8 207.93    25.99
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
# p-value: 0.001978
# Homocedasticidad=
# mean sq = 25.99 (varianza entre los residuales)
# suma de cuadrados del error = 207.93

# Interpretaci3N de varianza de los errores: (foto)

library(lmtest)
```

```
## Warning: package 'lmtest' was built under R version 4.5.1
```

```
## Cargando paquete requerido: zoo
```

```
##
## Adjuntando el paquete: 'zoo'
```

```
## The following objects are masked from 'package:base':
##
##      as.Date, as.Date.numeric
```

```
# modelo, es lo mismo a fit.lm
m <- lm(datos$harina ~ datos$trigo)
bptest(m) # Breusch-Pagan = homocedasticidad
```

```
##
## studentized Breusch-Pagan test
##
## data: m
## BP = 0.33274, df = 1, p-value = 0.5641
```

```
bptest(fit.lm) # p-value = 0.5641
```

```
##  
## studentized Breusch-Pagan test  
##  
## data: fit.lm  
## BP = 0.33274, df = 1, p-value = 0.5641
```

```
# Se acepta la H0 es homocedastica
```

```
fit.lm$model
```

```
##      datos$harina datos$trigo  
## 1           25           30  
## 2           30           28  
## 3           27           32  
## 4           40           25  
## 5           42           25  
## 6           40           25  
## 7           50           22  
## 8           45           24  
## 9           30           35  
## 10          25           40
```

```
fit.lm$coefficients
```

```
## (Intercept) datos$trigo  
## 74.115118 -1.353675
```

```
fit.lm$residuals
```

```
##           1           2           3           4           5           6           7  
## -8.5048544 -6.2122053 -3.7975035 -0.2732316  1.7267684 -0.2732316  5.6657420  
##           8           9          10  
##  3.3730929  3.2635229  5.0319001
```

```
mean(fit.lm$residuals) # media de los residuales es casi 0 = 4.883247e-16
```

```
## [1] -4.883247e-16
```

```
# (En la tesis si vas a hacer una, primero explica que se cumplen todos los supuestos  
#y los valores, de B0 y B1)
```

```
sqrt(0.6820) # sqrt de r
```

```
## [1] 0.8258329
```

```
# coeficiente de correlación = varianza = 0.8258329 = **linealidad** muy cercano a 1.
# correlación de -1 a 1
# Se acepta que es lineal y tiene una correlación muy alta.

# Fuerza de correlación, 0-0.1 indica que no existe, valor entre 0.7-1 es correlación muy alta.

# SSE = 207.9
mean(fit.lm$residuals)
```

```
## [1] -4.883247e-16
```

```
datos$yprima <- 74.11 - 1.3536 * datos$trigo # b0-b1*datos$trigo
datos$yprima
```

```
## [1] 33.5020 36.2092 30.7948 40.2700 40.2700 40.2700 44.3308 41.6236 26.7340
## [10] 19.9660
```

```
datos$recta <- fit.lm$fitted.values
datos$recta
```

```
## [1] 33.50485 36.21221 30.79750 40.27323 40.27323 40.27323 44.33426 41.62691
## [9] 26.73648 19.96810
```

```
datos$residuales <- datos$harina-datos$recta
datos$residuales
```

```
## [1] -8.5048544 -6.2122053 -3.7975035 -0.2732316 1.7267684 -0.2732316
## [7] 5.6657420 3.3730929 3.2635229 5.0319001
```

```
sum(datos$residuales^2) # 207.9251 = SSE
```

```
## [1] 207.9251
```

```
SSE <- sum(datos$residuales^2) # suma de cuadrados del error.
SSE/8 # 25.99064 varianza de los errores.
```

```
## [1] 25.99064
```

```
sqrt(SSE/8) # 5.098101 desviación estandar residual.
```

```
## [1] 5.098101
```